

Instituto Federal de Educação, Ciência e Tecnologia do Ceará

Engenharia Mecatrônica

Visão Computacional

Prof. Pedro Pedrosa

Relatório N^o 1 - Técnicas básicas de PDI

Rafael Virginio

Fortaleza

Setembro de 2019

Sumário

1	Introdução	2
2	Filtros Passa-baixa	2
2.1	Filtro da Média	2
2.2	Resultado e Discussões	3
2.3	Conclusões	5
2.4	Filtro da Mediana	6
2.5	Resultados e Discussões	6
2.6	Conclusões	8
2.7	Filtro Gaussiano	9
2.8	Resultados e Discussões	9
2.9	Conclusões	11
3	Filtros Passa-Alta	12
3.1	Filtro Sobel	12
3.2	Resultados e Discussões	13
3.3	Conclusões	16
3.4	Filtro Prewit	17
3.5	Discussões e Resultados	18
3.6	Conclusões	20
3.7	Filtro Laplaciano	20
3.8	Resultados e Discussões	21
3.9	Conclusões	22
4	Outras operações	24
4.1	Cálculo do Histograma	24
4.2	Resultados e discussões	24
4.3	Conclusões	25
4.4	Equalização do histograma	26
4.5	Resultados e Discussões	26
4.6	Conclusões	28
4.7	Limearização	28
4.8	Resultados e discussões	29
4.9	Conclusões	30
4.10	Multilimearização	31
4.11	Resultados e Discussões	31
4.12	Conclusões	31

1 Introdução

Este relatório tem como objetivo principal apresentar a implementação, resultados e conclusões sobre a aplicação de técnicas básicas de PDI em imagens. Neste relatório será apresentado os seguintes métodos de filtros passa-baixa: Média, Mediana e Gaussiana, bem como também filtros passa-alta: Laplaciano, Prewit e Sobel, como também operações sobre o cálculo, equalização e apresentação de histograma, limiarização e multilimiarização.

2 Filtros Passa-baixa

Filtros passa baixa são um tipo de dispositivo que permite a passagem das frequências de uma certa faixa e rejeita ou atenua as frequências fora dessa faixa. No caso deste filtro as frequências baixas são captadas e o que estiver fora dessa faixa de frequência é filtrada.

2.1 Filtro da Média

O fitro da média é um filtro linear de suavização e sua utilidade está na nescessidade de exibir partes específicas de uma imagem, sua operação ocorre em uma região de interesse, determinada pelo Kernel(máscara) cujo funcionamento é similar a uma integral no domínio do tempo discreto.

$$g(x, y) = \frac{\sum_{ki=0}^N \sum_{kj=0}^M w(ki, kj) f(i+ki, j+kj)}{N \times M} \quad (1)$$

No qual i e j são o pixel em questão da imagem, N e M representa o tamanho do kernel, e g(x, y) é o novo ponto da imagem e a matriz do kernel w é unitária. No domínio discreto 2D em torno pixel essa é a representação da operação de integração. Ao longo da imagem essa operação pode ser entendida como a convolução dos dois sinai bi-dimensionais discretos, cuja operação é representada pela seguinte equação:

$$w * f = \sum_{n=0}^N \sum_{m=0}^M f[x, y] g[x - n, y - m] \quad (2)$$

A imagem utilizada para a aplicação desse filtro foi a seguinte:




Figura 1: tigerfacegray

2.2 Resultado e Discussões

Aqui analisaremos o resultado das saídas da imagem nas implementações feitas , em outras palavras discutiremos a influência do tamanho do kernel e do número de aplicações do filtro além de outras discussões pertinentes.

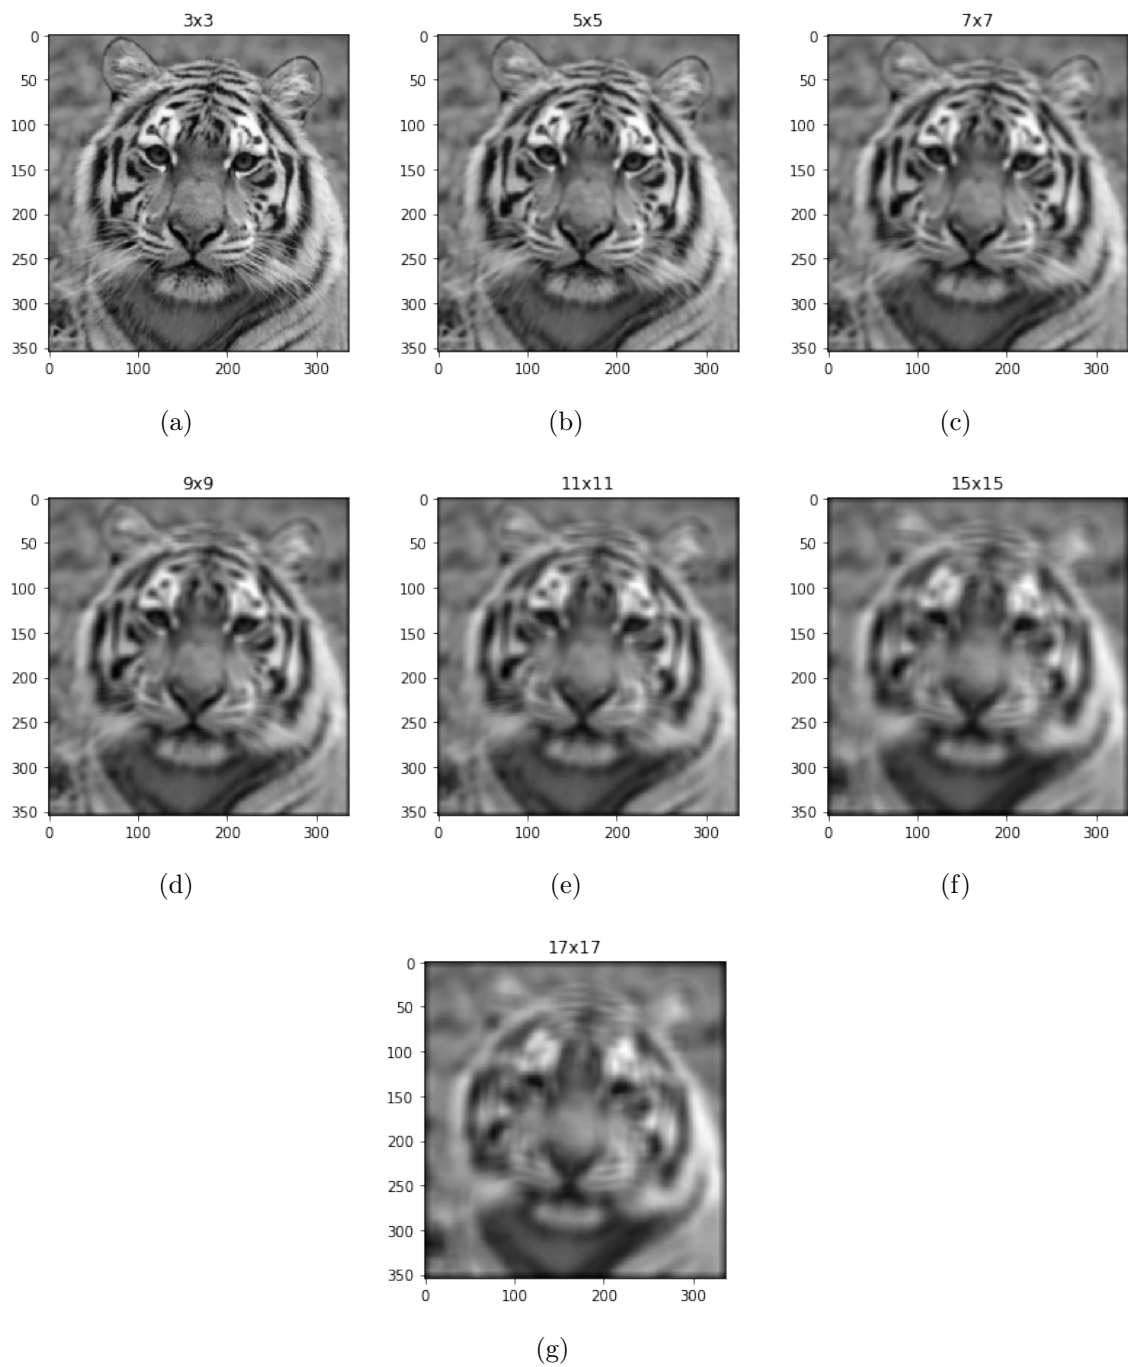


Figura 2: Resultaods da imagem após a aplicação do filtro da média com kernels diferentes




Figura 3: resultado da aplicação do filtro da média por 50 vezes

A escolha de um kernel(máscara) adequado está relacionado a necessidade de minimizar detalhes da imagem não relevantes para a obtenção das informações desejadas, esse filtro faz com que imagens menores que o tamanho do kernel fiquem borradas. Note na figura 2 que o kernel de tamanho 3x3 borrou os menores detalhes onde os principais pixels eram menores que o kernel, enquanto o kernel de 17x17 de forma bem perceptível borrou grandes detalhes da imagem em geral. Já a figura 3 exibe a saída da imagem submetida ao filtro, sucessivamente, por 50 vezes. A transição entre grandes diferenças se tornou mais suave, note que onde originalmente regiões bastante distintas entre preto e branco agora estão em uma escala de cinza de transição. A consequência disso foi a atenuação de valores elevados deslocando regiões originalmente brancas em tons suaves de cinza. Em especial nas bordas da imagem, reduzindo a área útil da mesma.

2.3 Conclusões

É conveniente usar o filtro da média quando se quer remover distorções não-lineares nas imagens, causadas por transições abruptas. O efeito de borramento traduz o pixel da região para um valor médio e isso implica que sua aplicação deve ser cuidadosa por uma série de fatores como caso kernel seja grande demais a operação irá representar uma grande parte da imagem por uma média, havendo percas e caso as aplicações forem sucessivas haverá uma tendência a perder informações da imagem original a cada iteração. No

geral, o filtro da média apresenta grande simplicidade, linearidade e é elementar, pode proporcionar resultados satisfatórios de acordo com a aplicação e parametrização correta.

2.4 Filtro da Mediana

Assim como o filtro da média, o filtro da mediana é um filtro passa-baixa que promove atenuação em transições com frequência abaixo da frequência de corte de filtro, causando um borramento na imagem. Mas, sua operação não é linear, pois é utilizado um operador estático, a mediana. Sua operação não consiste na convolução discreta de sinais bi-dimensionais, mas sim no cálculo da mediana em uma região de interesse, chamada de máscara(kernel).




Figura 4: tigerfacegraymediana

2.5 Resultados e Discussões

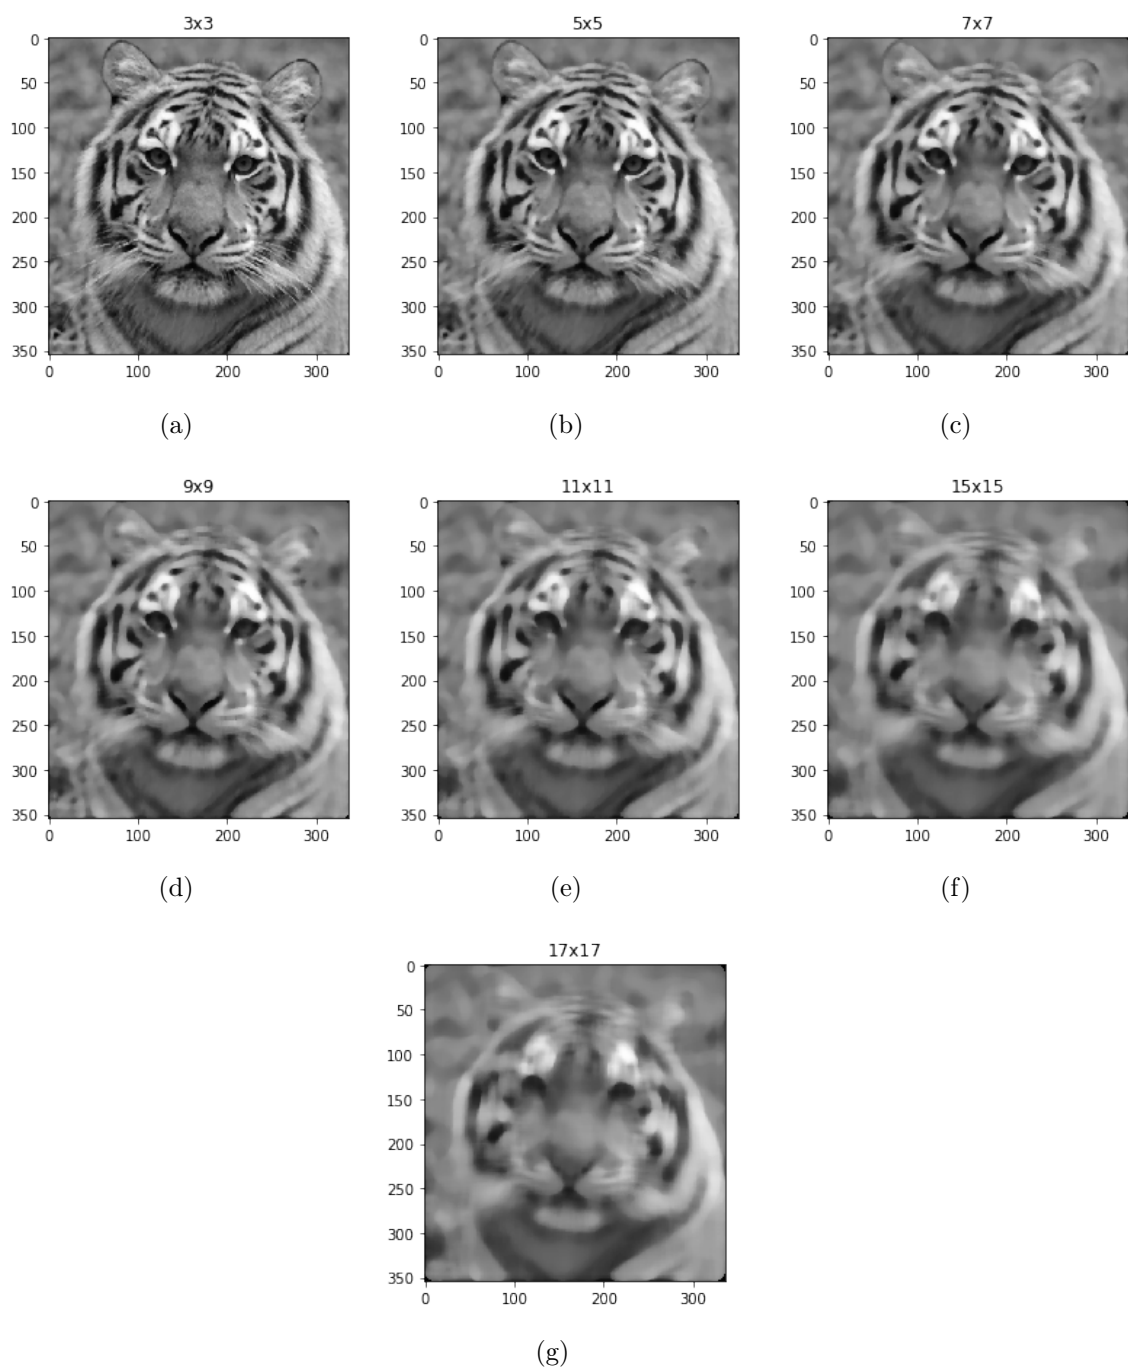


Figura 5: Resultaods da imagem após a aplicação do filtro da mediana com kernels diferentes

Submetendo a imagem a variação do tamanho do kernel nota-se que assim como o filtro da média, kernels maiores acarretam em uma distorção maior na imagem, porém com resultados diferentes. O filtro da mediana borra com mais eficácia objetos menores que o seu tamanho, percebe-se que a utilização do kernel 17x17 resultou em uma perda maior que no filtro da média.



Figura 6: imagem que mostra a saída do filtro da mediana aplicado 50 vezes

A imagem acima mostra a saída de uma aplicação do filtro da mediana feita por 50 vezes, diferente do filtro da média que tende a excluir os objetos menores, no filtro da mediana temos menores perdas das características originais.

2.6 Conclusões

Após a operação do filtro da mediana o resultado é similar ao filtro da média, produzindo borramento, por ser um filtro passa-baixa. Entretanto, com algumas diferenças, como por exemplo o filtro da média atenua transições abruptas como bordas e detalhes, o filtro da mediana tende a preservar melhor detalhes finos. Quando se utiliza kernels maiores a preservação de detalhes finos é prejudicada e faz com que opere como o filtro da média. Contudo, ele promove menos perdas na imagem após aplicações sucessivas, devido ao fato de que o valor matemático da mediana ser menor suceptível a transformações do que a média aritmética. Essa característica matemática da mediana a torna eficaz perante a

média na remoção de ruídos de alta frequência e pequena intensidade.

2.7 Filtro Gaussiano

O filtro Gaussiano, atenua transições e promove borramentos já que também é um filtro passa-baixa. Sua implementação dar-se a partir da convolução da imagem com umas máscaras gaussianas tri-dimensionais, gerada por meio da seguinte equação:

$$w(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2 + y^2}{2\sigma^2}}$$




Figura 7: Imagem original para a aplicação do filtro gaussiano

2.8 Resultados e Discussões

O filtro gaussiano tem algumas peculiaridades que valem a pena salientarmos na análise dos resultados que viram a seguir

Assim como o filtro da média e mediana o filtro Gaussiano é do tipo passa-baixa e provoca borramentos na imagem, entretanto o filtro da média pondera igualmente os pixels vizinhos a operação do filtro Gaussiano não. O kernel desse filtro é baseado na distribuição normal da função densidade de probabilidade, cujo elemento central representa o valor máximo da gaussiana e caem de acordo com a função até atingir valores zeros infinitos.

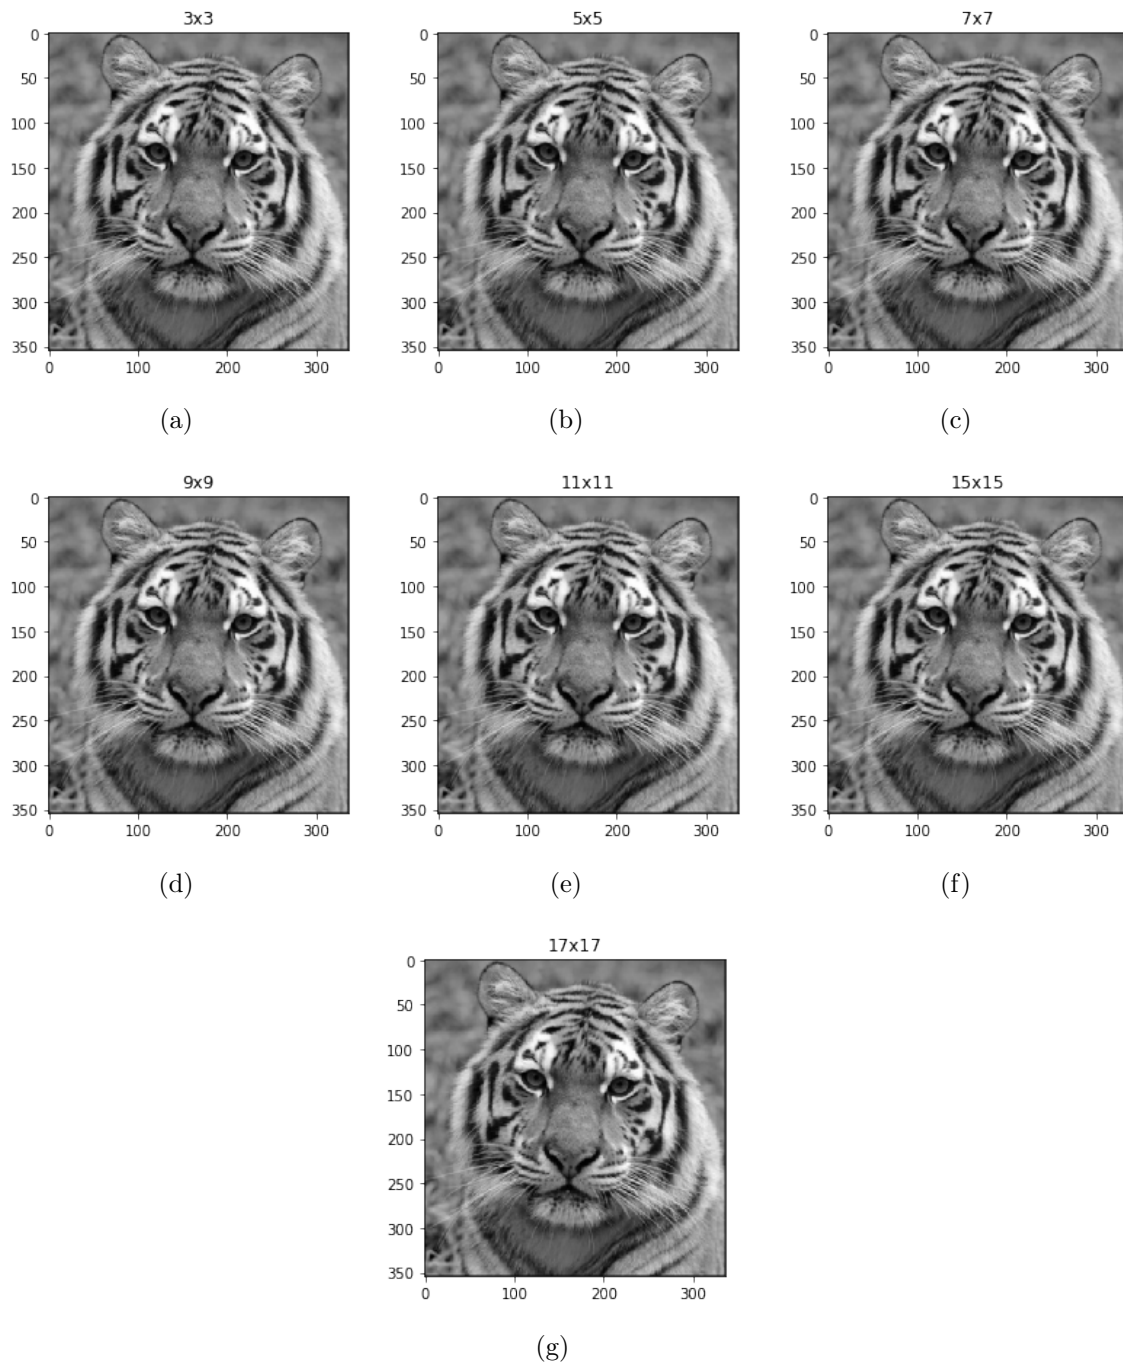


Figura 8: Resultaods da imagem após a aplicação do filtro gaussiano com kernels diferentes

Veja a figura 8, submetendo a uma variação do tamanho do kernel notou-se que kernel menores, como 3x3 tem mais impacto em uma imagem complexa, pois kernels menores realçam regiões contidas em si. Enquanto os kernels maiores os contornos principais da imagem resultam em uma possível identificação e relação com a imagem original.

Na figura 9 imagem a foi uxado um kernel de 3x3 com aplicação 50 vezes do filtro, já a

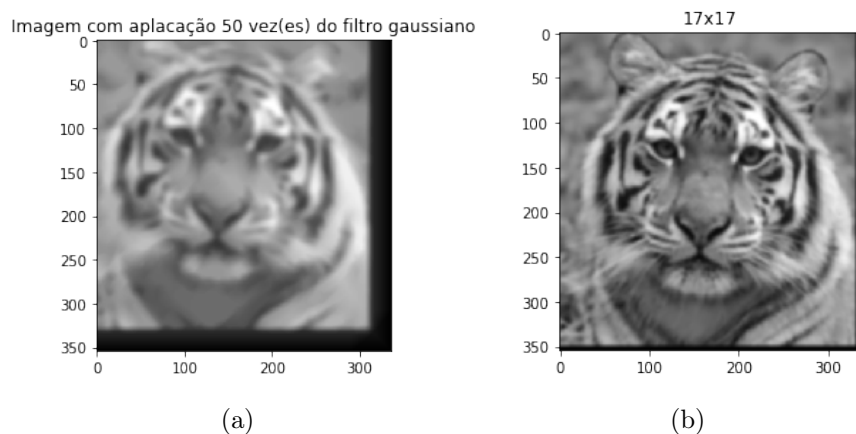


Figura 9: Resultaods da imagem após a aplicação do filtro gaussiano diverssas vezes

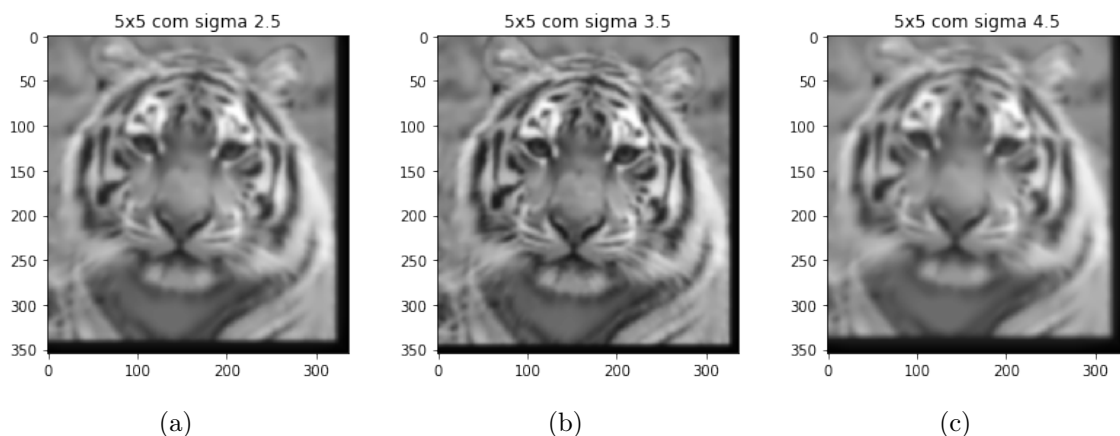


Figura 10: Resultaods da imagem após a aplicação do filtro gaussiano com sigmas dife-
rentes

imagem b foi usado um kernel de 17x17 aplicado 10 vezes o filtro gaussiano. Vale resaltar que há um parâmetro na gaussiana que pode ser ajustado para configuração do kernel que é o desvio padrão, o sigma, também conhecido como abertura da curva. Na figura 10 é possível observar essa variação de sigma, imagens a, b e c embora tenham sido submetidas ao mesmo kernel de 5x5 e ao mesmo número de 10 aplicações do filtro a variação do kernel é visível.

2.9 Conclusões

Como era esperado o filtro Gaussiano também produz borramentos já que é um filtro passa-baixa e sua aplicação é semelhante a uma média ponderada com pesos referentes aos valores da Gaussiana. Por esse motivo seu efeito de borramento dar-se do centro

para as bordas, enquanto o filtro da média traz o pixel para o valor médio da região o filtro Gaussiano pondera de forma maior o pixel central, tendendo a preservar a imagem original. Constatou-se que o aumento deste parâmetro de abertura da curva Gaussiana, o desvio padrão ou sigma, tende a tender a tornar a operação Gaussiana semelhante ao filtro da média, visto que a ponderação do centro do kernel para a vizinhança é menor.

3 Filtros Passa-Alta

Um filtro passa-alta é um filtro que permite a passagem das frequências altas com facilidade, porém atenua a amplitude das frequências abaixo da frequência de corte. A quantidade de atenuação varia de filtro pra filtro. Nessa seção vamos ver os filtros Prewit, Sobel e Laplaciano.

3.1 Filtro Sobel

O filtro Sobel é um operador linear, cujo desenvolvimento está pautado em conceitos de diferenciação no domínio do tempo discreto. Enquanto a aplicação do filtro da média podem ser entendidos como uma integração, o operador sobel representa uma derivação de primeira ordem no espaço, representada pelo gradiente, que é a taxa de variação, nas direções do sinal bidimensional. A definição dessa derivada é dada por:

$$\frac{\partial f}{\partial x} = f(x+1) - f(x)$$

E o vetor gradiente é representado por:

$$grad(f) = \begin{pmatrix} gx \\ gy \end{pmatrix} = \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix}$$

Utilizando operadores de vizinhança diagonais o valor dos gradientes dado um ponto central no sinal é:

$$\frac{\partial f}{\partial x} = [f(x-1, y+1) + 2f(x, y+1) + f(x+1, y+1)] - [f(x-1, y-1) + 2f(x, y-1) + f(x+1, y-1)]$$

$$\frac{\partial f}{\partial y} = [f(x+1, y-1) + 2f(x+1, y) + f(x+1, y+1)] - [f(x-1, y-1) + 2f(x-1, y) + f(x-1, y+1)]$$

O efeito do vetor gradiente pode ser traduzido pela aplicação de duas máscaras, nas direções x e y da imagem da seguinte forma:

Máscara horizontal:

$$\begin{array}{c} \text{.....}x-1 \quad x \quad x+1\text{....} \\ y-1... \begin{pmatrix} -1 & 0 & 1 \end{pmatrix} \\ y... \begin{pmatrix} -2 & 0 & 2 \end{pmatrix} \\ y+1... \begin{pmatrix} -1 & 0 & 1 \end{pmatrix} \end{array}$$

Máscara vertical:

$$\begin{array}{c} \text{.....}x-1 \quad x \quad x+1\text{....} \\ y-1... \begin{pmatrix} -1 & -2 & -1 \end{pmatrix} \\ y... \begin{pmatrix} 0 & 0 & 0 \end{pmatrix} \\ y+1... \begin{pmatrix} 1 & 2 & 1 \end{pmatrix} \end{array}$$

É importante ressaltar que o somatório dos valores da máscara devem ser sempre zero, por ser um operador derivativo. A magnitude imposta pelo vetor gradiente é transmitida ao pixel pela seguinte equação:

$$M(x, y) = \sqrt{gx^2 + gy^2}$$

A equação para cálculo dos gradientes considera um peso maior aos centrais, diferente do kernel do filtro de Prewit que vamos ver futuramente, que atribui um peso identico aos valores adjacentes e diagonais da imagem.

3.2 Resultados e Discussões

Tanto o filtro Sobel quanto o Prewit representam efeitos derivativos na função de intensidade luminosa da imagem, mas o filtro Sobel promove melhores suavizações na imagem, justificado pelo peso maior que se leva aos pixels adjacentes no cálculo do vetor gradiente daquele pixels. Ambos são bons para realce de bordas, com características de operação similares. Entretanto, prefere-se o filtro Sobel por conta da leve suavização promovida nas regiões mais próximas do pixel em questão, esse efeito também tende a apresentar respostas menos ruidosas ainda que o filtro de Prewit.




Figura 11: Imagem original para a aplicação do filtro Sobel




Figura 12: Resultaods da imagem após a aplicação do filtro sobel com kernels diferentes

A figura 12 mostra a saída da figura 11 que foi submetida a variação do tamanho do kernel, constatou-se que máscaras de tamanhos menores, como 3x3, demonstram-se mais eficazes quando o objetivo é realce de bordas, pois a operação de gradiente do filtro Sobel é valorizado em regiões próximas ao pixel, enquanto que em kernels maiores, como 17x17, os valores de gradientes destoam devido a distância entre os pixels, proporcionando um valor de variação não confiável para a região.



Figura 13: Imagem submetida ao filtro Sobel por 50 vezes

Aplicações sucessivas corrompem a imagem original, como visto na figura 13. Por ser um operador derivativo, o cálculo iterativo e prolongado converge para valores fora do domínio do tempo da função de imagem.

3.3 Conclusões

O filtro Sobel ressalta bordas de maneira eficaz, mas oferece um custo computacional maior para o cálculo das derivadas direcional(vetores gradientes) em cada direção, sendo necessário a utilização de dois kernels para tal. Sobel oferece uma ponderação maior aos vizinhos adjacentes do que os diagonais se comparado com o próximo filtro que veremos, que é o de Prewitt. Devido a essa característica o filtro de Sobel é excelente para caracterização de bordas em regiões finas, principalmente com objetos distintos entre si.

3.4 Filtro Prewit

O filtro Prewit é um operador linear, cujo seu desenvolvimento vem oautado em conceitos de diferenciação no domínio do tempo discreto. O operador de prewit representa uma derivação de primeira ordem no espaço, representada pelo gradiente(taxa de variação) nas direções do sinal bidimensional. A definição dessa derivada é dada por:

$$\frac{\partial f}{\partial x} = f(x+1) - f(x)$$

E o vetor gradiente é representado por:

$$grad(f) = \begin{pmatrix} gx \\ gy \end{pmatrix} = \begin{pmatrix} \frac{\partial f}{\partial x} \\ \frac{\partial f}{\partial y} \end{pmatrix}$$

Utilizando operadores de vizinhança diagonais o valor dos gradientes dado um ponto central no sinal é:

$$\frac{\partial f}{\partial x} = [f(x-1, y+1)+2f(x, y+1)+f(x+1, y+1)]-[f(x-1, y-1)+2f(x, y-1)+f(x+1, y-1)]$$

$$\frac{\partial f}{\partial y} = [f(x+1, y-1)+2f(x+1, y)+f(x+1, y+1)]-[f(x-1, y-1)+2f(x-1, y)+f(x-1, y+1)]$$

O efeito do vetor gradiente pode ser traduzido pela aplicação de duas máscaras, nas direções x e y da imagem da seguinte forma:

Máscara horizontal:

$$\dots\dots\dots x-1 \quad x \quad x+1 \dots\dots$$

$$\begin{matrix} y-1\dots \\ y\dots \\ y+1\dots \end{matrix} \begin{pmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{pmatrix}$$

Máscara vertical:

$$\dots\dots\dots x-1 \quad x \quad x+1 \dots\dots$$

$$\begin{matrix} y-1... \\ y... \\ y+1... \end{matrix} \begin{pmatrix} -1 & -2 & -1 \\ 0 & 0 & 0 \\ 1 & 2 & 1 \end{pmatrix}$$

É importante ressaltar que o somatório dos valores da máscara devem ser sempre zero, por ser um operador derivativo. A magnitude imposta pelo vetor gradiente é transmitida ao pixel pela seguinte equação:

$$M(x, y) = \sqrt{gx^2 + gy^2}$$

3.5 Discussões e Resultados




Figura 14: Imagem original para a aplicação do filtro Prewit

Assim com o filtro Sobel, o de Prewit proporciona um efeito derivativo na imagem, porém com uma certa suavidade, gerando resultados mais consistentes para o destaque de transições suaves. A justificativa reside no fato de ser um filtro de efeito derivativo de primeira ordem(chamado de gradiente), combinando os valores referentes as variações nas duas direções da imagem. O operador de Prewit leva em consideração eliminar transições suaves(por razão do efeito quase nulo da derivada em região constante) e destacar transições abruptas. No geral, o filtro Prewit é eficaz em destacar bordas e retirar transições suaves. As imagens a seguir exibem as funcionalidades descritas.




Figura 15: Resultaods da imagem após a aplicação do filtro prewit com kernels diferentes

Submetendo a figura 14 a aplicação com diferentes kernels do filtro prewit o resultado pode ser observado na figura 15. Constatou-se que kernel de tamanhos menores, como 3x3, demonstram-se mais eficazes quando o objetivo é realce de bordas, pois a operação de gradiente do filtro prewit é valorizada em regiões próximas ao pixel, enquanto que em kernels maiores, como 17x17, os valores de gradiente destoam devido a distância entre

pixels, proporcionando um valor de variação não confiável para a região.



Figura 16: Imagem submetida a aplicação de filtro Prewit por 50 vezes

Quanto a aplicações sucessivas vemos como resultado a figura 16. Por ser um operador de derivada, o cálculo iterativo e prolongado converge para valores fora do domínio da função de imagem, assim a imagem original acaba por ficar corrompida.

3.6 Conclusões

O filtro de Prewit é bastante eficaz para a detecção de bordas, fator justificado pela operação matemática de derivação de primeira ordem, que ressalta apenas transições em primeira instância. Entretanto oferece um maior custo computacional, visto que há necessidade de duas operações de convolução na imagem por meio dos kernels verticais e horizontais.

3.7 Filtro Laplaciano

O filtro de Laplace, mediante suas características de filtro passa-alta atenua interferências abaixo da frequência de corte do filtro. É um operador linear, cujo seu desenvolvimento está pautado em conceitos de diferenciação no domínio do tempo discreto. Enquanto a aplicação dos filtros de média podem ser entendidos como uma integração, o laplaci-

ano representa uma derivação do sinal, em específico uma derivação de segunda ordem, representada no domínio do tempo discreto por:

$$\frac{\partial^2 f}{\partial x^2} = f(x) + f(x - 1) - 2f(x)$$

Porém, para o caso de sinais bidimensionais, como a imagem, é utilizado o conceito de 8 adjacentes vizinhos, temos:

$$\begin{aligned}\frac{\partial^2 f}{\partial x^2} &= f(x + 1, y) + f(x - 1, y) - 2f(x) \\ \frac{\partial^2 f}{\partial x^2} &= f(x + 1, y + 1) + f(x - 1, y + 1) - 2f(x) \\ \frac{\partial^2 f}{\partial x^2} &= f(x, y + 1) + f(x, y - 1) - 2f(x) \\ \frac{\partial^2 f}{\partial x^2} &= f(x - 1, y + 1) + f(x - 1, y - 1) - 2f(x)\end{aligned}$$

O efeito derivativo final é a soma das derivadas parciais. Dessa forma, isto pode ser traduzido para o kernel do filtro ser representado da seguinte forma:

$$\begin{array}{ccccccc} & & \dots & x - 1 & x & x + 1 & \dots \\ y - 1 \dots & \left(\begin{array}{ccc} 1 & 1 & 1 \\ 1 & -8 & 1 \\ 1 & 1 & 1 \end{array} \right) \\ y \dots & & & & & & \\ y + 1 \dots & & & & & & \end{array}$$

A aplicação do filtro segue da mesma forma que o filtro da média, uma representação adaptada da convolução digital para imagens.

3.8 Resultados e Discussões

Por possuir efeito derivativo, a aplicação do filtro de Laplace ressalta especificamente transições. Analogamente a derivada (taxa de variação) no regime de tempo contínuo, transições abruptas, como em um degrau, possuem elevados valores de derivadas e situações de constância apresentam valores nulos de derivadas. Este conceito é traduzido no domínio de imagens da seguinte forma: transições representam mudanças em valores de pixels, ou ainda variações na escala de cinza. Esta característica confere ao filtro a capacidade de ressaltar contornos de forma eficaz, visto que em geral contornos em objetos dentro de uma imagem são transições de valores na intensidade dos pixels.




Figura 17: Imagem original para a aplicação do filtro laplaciano

Submetendo a figura 17 ao filtro laplaciano temos como saída o conjunto de imagens da figura 18. Contata-se que kernels de tamanhos menores como 3x3 impactam bastante em uma imagem complexa, tornando pouco visível, pois kernels menores realçam regiões contidas em si. Enquanto que em kernels maiores os contornos principais da imagem, resultando em uma possível identificação e relação com a imagem original. Já com relação a aplicações sucessivas do filtro temos como saída a figura 19, fica demonstrado que há um realce em regiões de transição, porém a partir de dado limite o excessivo trabalho do filtro acaba por corromper a imagem original.

3.9 Conclusões

Por ser um operador derivativo de segunda ordem o filtro laplaciano ressaltar transições muito bem, atenuando regiões cujo não há mudança de intensidade luminosa. Comparando aos filtros Gaussiano e da Mediana sua operação pode ser entendida como complementar, Laplace ressaltar bordas e atribui intensidade nula a regiões contantes, mas também favorece a aparição de ruídos, os filtros de borrar tendem a retirar o ruído, porém atenuam as restrições, tendendo a deixar a imagem homogênea.




Figura 18: Resultaods da imagem após a aplicação do filtro laplaciano com kernels diferentes

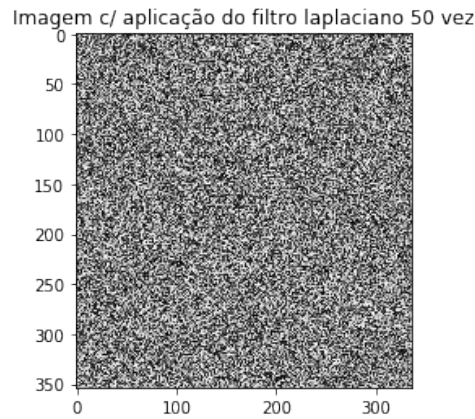


Figura 19: Imagem submetida a aplicação do filtro laplaciano por 50 vezes

4 Outras operações

4.1 Cálculo do Histograma

Chama-se de histograma de uma imagem a relação entre valores de intensidade da mesma($r[k]$) e número de pixels associados($n[k]$), onde k representa o k -ésimo valor de intensidade contido no intervalo

$$0 \leq k \leq L - 1$$

com L sendo o máximo valor de intensidade de acordo com a resolução da imagem. Tal relação é expressa graficamente na forma de uma distribuição($h[r[k]]$), no qual seu eixo vertical possui a quantidade de pixels associada ao valor de intensidade disposto no eixo horizontal.

4.2 Resultados e discussões

Aplicando o histograma para a imagem acima temos o seguinte resultado:

Percebe-se que a distribuição do histograma está diretamente relacionada com a intensidade da cor dominante na mesma, note que a elevação de pixels no gráfico corresponde a pixels mais escuros, mais próximos do preto, já as partes mais abaixo correspondem aos pixels mais claros, mais próximos do branco.

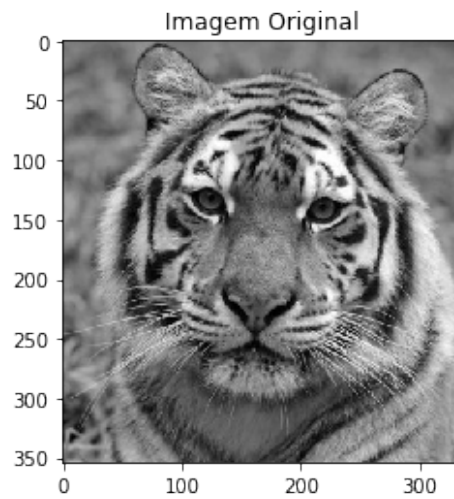


Figura 20: Imagem original para a aplicação do histograma




Figura 21: Histograma da figura 17

4.3 Conclusões

O calculo de histogramas é uma importante ferramenta visual para identificação de padrões de totalidade da imagem, é possível identificar predominância de sombras(imagens escuras ou com pouco contraste) ou o contrário, como identificar imagens equalizadas, que devem possuir um histograma com distribuição bastante homogênea.

4.4 Equalização do histograma

No âmbito da equalização de histogramas dar-se destaque a técnica de normalização, que pode provêr melhoramento de contraste em imagem predominantemente brancas ou escuras. Tal técnica baseia-se na redistribuição dos valores de intensidade da imagem na escala de cinza. A aplicação consiste em uma transformação(T) na imagem ($g(x,y)$) da seguinte forma:

$$h(x, y) = T[g(x, y)]$$

No qual($h(x,y)$) é uma imagem após o processo de normalização. Tal transformação(T) pode ser expressa da seguinte forma:

$$h(i, j) = \frac{g(i, j) - \min(g(x, y))}{\max(g(x, y) - \min(g(x, y)))} \times I_{max}$$

$$i = 0, 1, 2 \dots M$$

$$j = 0, 1, 2 \dots N$$

Sendo, $h(i,j)$ o novo pixel da imagem, $g(i,j)$ o pixel da imagem original, $\min(g(x,y))$ o mínimo e máximo valor de intensidade na imagem respectivamente, com i e j variando até o tamanho da imagem e I_{max} a intensidade máxima na nova escala adotada.

4.5 Resultados e Discussões

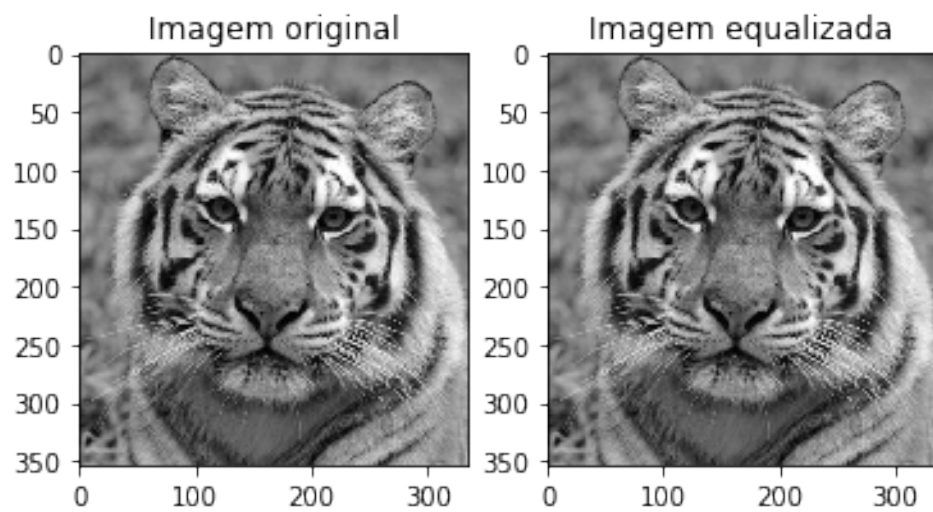


Figura 22: A esquerda a imagem original e a direita a imagem equalizada

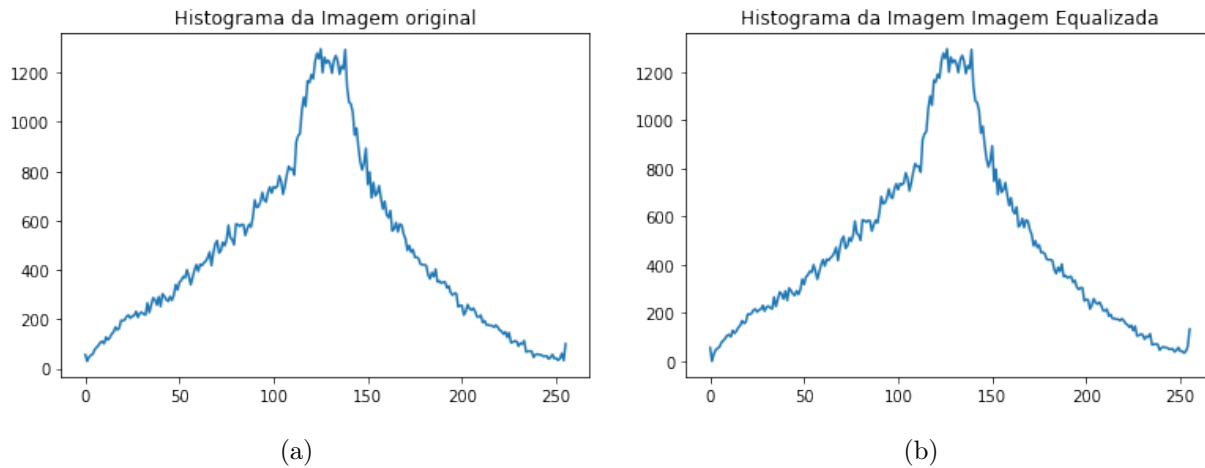


Figura 23: A esquerda histograma da imagem original e a direita histograma da imagem equalizada

Percebe-se que o histograma original da imagem é bastante concentrado em regiões de intensidade entre 50 e 150. Porém, a aplicação da técnica de normalização tornou a distribuição um pouco mais homogênea, deixando os valores de intensidade mais distos entre si.

4.6 Conclusões

A normalização de histogramas permite o equilíbrio em regiões que apresentam valores de intensidade luminosa próximas, tornando a distribuição de intensidade mais homogênea. A ideia por trás deste método é tornar a diferença entre cores na imagem em questão, aumentando o contraste da mesma. Entretanto, é importante salientar que a efetividade destas técnicas está pautada na escolha de regiões que apresentam valores de intensidade próximos entre si. a operação pode não surtir efeito ao aplicar-se em uma imagem por completo e com grande faixa de valores de intensidade.

4.7 Linearização

O conceito de linearização é introduzido em um processo de transformação na imagem com base em lineares pré-definidos. A transformação ocorre mediante a aplicação da seguinte função:

$$g(x, y) = \max, \text{ se } f(x, y) > T \text{ ou } g(x) = 0, \text{ se } f(x, y) \leq T$$

onde $g(x)$ representa o valor de intensidade no ponto em questão.

4.8 Resultados e discussões




Figura 24: Imagem original para a aplicação da linearização

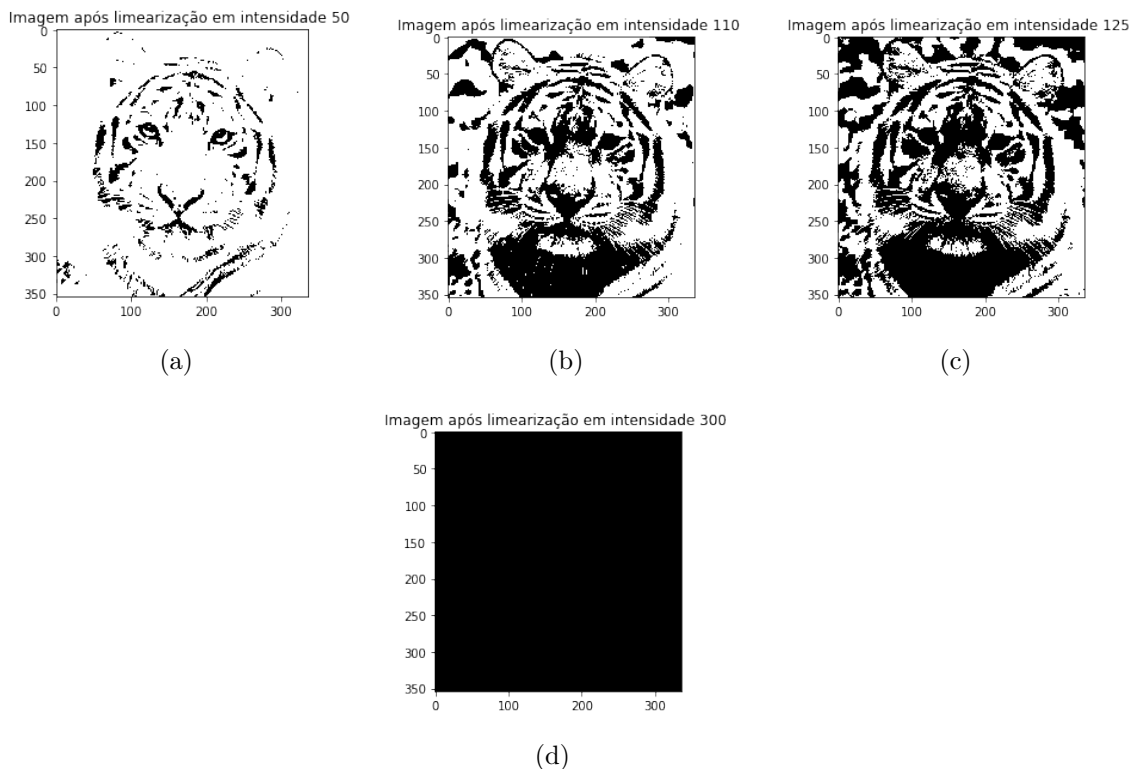


Figura 25: Resultados da imagem após a aplicação de diferentes intensidades de limiarização

Veja que a intensidade da limiarização tem grande influência na saída da imagem original (figura 21). Nota-se que é possível enfatizar os objetos pretos, exibindo-os e excluindo o resto da imagem, podemos observar isso nos limiares nas faixas entre 110 e 125. Porém quando a intensidade do limiar é grande demais os objetos pretos ficam visíveis em demasia e acaba por corromper a imagem original como visto na imagem d na figura 22.

4.9 Conclusões

O processo de limiarização é bastante intuitivo e rápido em sua execução, devido a sua fácil implementação, porém não deixa de ser uma ferramenta poderosa para o caso de segmentação de objetos com cores bastantes ditas. É importante salientar que antes de aplicar a limiarização deve-se utilizar o histograma da imagem como um direcional para a definição do limiar, pois a distribuição de intensidades por pixels nos transmite uma representação das cores da imagem.

4.10 Multilinearização

O conceito de multilinearização é similar ao da linearização simples, apenas adotam-se mais de um limiar, resultando em mais regiões de transformação na imagem. A transformação ocorre mediante a aplicação da seguinte função:

$$g(x, y) = 0, \text{ se } f(x, y) < Linf, \text{ ou } g(x, y) = h, \text{ se } Lin < f(x, y) < Lsup, \text{ ou } g(x, y) = max, \text{ se } f(x, y) \geq Lsup$$

No qual, $Linf$ é o limite inferior definido, $Lsup$ o limite superior e h o valor de transformação da região adicionada.

4.11 Resultados e Discussões

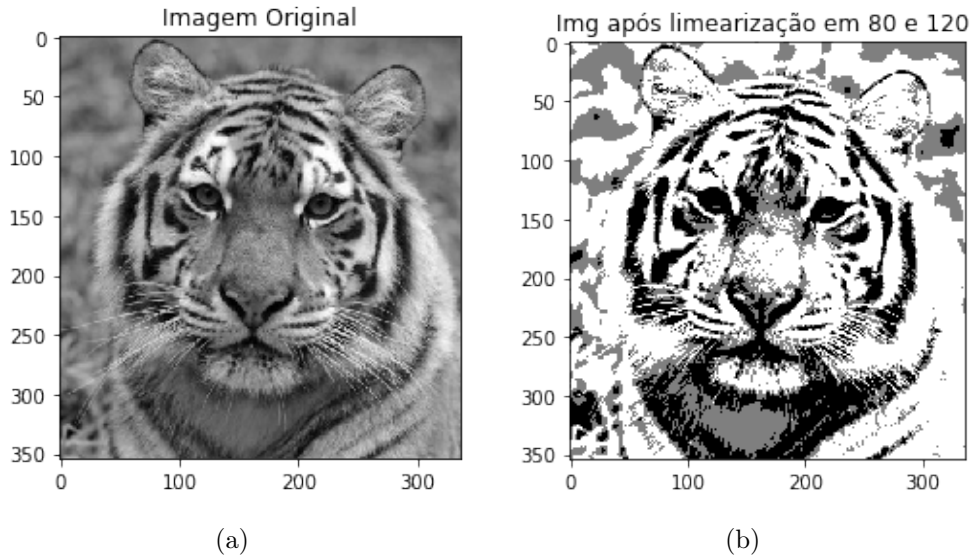


Figura 26: A esquerda imagem original e a direita imagem após multilinearização em 80 e 120

Note que com a multilinearização foi possível separar bem as cores da imagem, alíás esse método se mostra bastante útil pra isso.

4.12 Conclusões

O processo de multilinearização é a expansão da linearização. Torna-se vantajoso para a segmentação de objetos de cores distintas de branco ou preto, que é a limitação da linearização simples. Para a segmentação em imagens que possuem diversas variações de iluminação também é recomendável utilizar a multilinearização, pelo mesmo fator já citado.

Referências